心跳信号分类预测

李阳

山东大学计算机科学与技术学院

2019 级智能班

2021 年 5 月 26 日

问题分析

1. 多分类问题
2. 数据量大
3. 特征是一串心跳序列
4. 结果提交的是 4 种不同心跳信号预测的概率，而非单一的预测所属分类

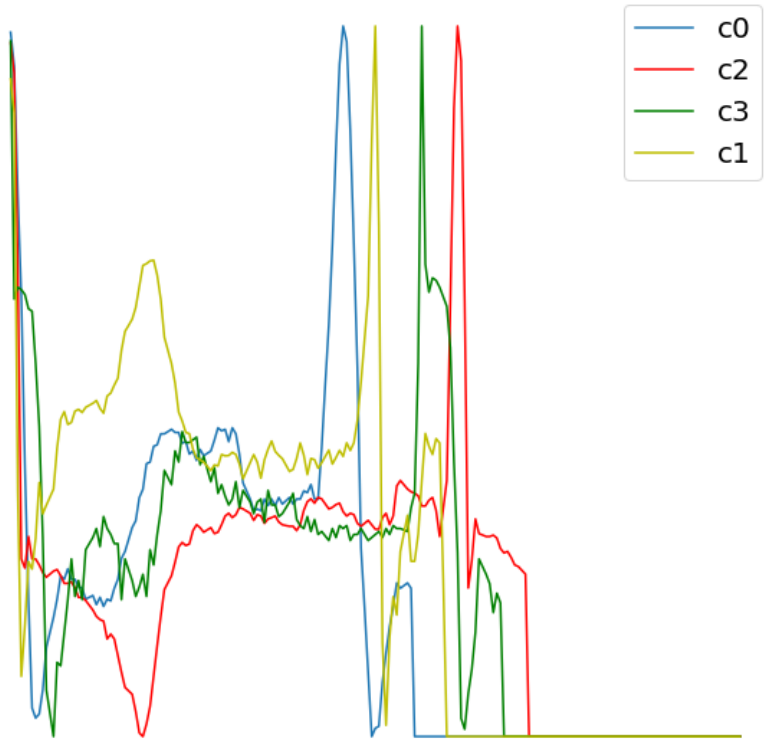

数据查看

1. 实际是多个特征伪装成的一个特征
2. 无匿名特征（与贷款违约预测相比）
3. 无缺省值
4. 特征之间关联性较大，主要是时序上的关联

	id	heartbeat_signals	label
0	0	0.9912297987616655,0.9435330436439665,0.764677...	0.0
1	1	0.9714822034884503,0.9289687459588268,0.572932...	0.0
2	2	1.0,0.9591487564065292,0.7013782792997189,0.23...	2.0
3	3	0.9757952826275774,0.9340884687738161,0.659636...	0.0
4	4	0.0,0.055816398940721094,0.26129357194994196,0...	2.0
99995	99995	1.0,0.677705342021188,0.22239242747868546,0.25...	0.0
99996	99996	0.9268571578157265,0.9063471198026871,0.636993...	2.0
99997	99997	0.9258351628306013,0.5873839035878395,0.633226...	3.0
99998	99998	1.0,0.9947621698382489,0.8297017704865509,0.45...	2.0
99999	99999	0.9259994004527861,0.916476635326053,0.4042900...	0.0

数据处理

1. 通过替换数据类型、用 category 类代替 object 类的方法来减小内存占用
2. 将 heartbeat_signals 列分割成小的特征
3. 观察到 id 列无缺省值无异常值，所以在模型拟合时可以去掉，直接用 DataFrame 的默认索引代替 id 值

	id	t0	t1	t2	t3	t4	t5	t6	t7	t8	...	t196	t197	t198	t199	t200	t201	t202	t203	t204	label
0	0.0	0.991211	0.943359	0.764648	0.618652	0.379639	0.190796	0.040222	0.026001	0.031708	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
1	1.0	0.971680	0.929199	0.572754	0.178467	0.122986	0.132324	0.094421	0.089600	0.030487	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
2	2.0	1.000000	0.958984	0.701172	0.231812	0.000000	0.080688	0.128418	0.187500	0.280762	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	2.0
3	3.0	0.975586	0.934082	0.659668	0.249878	0.237061	0.281494	0.249878	0.249878	0.241455	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
4	4.0	0.000000	0.055817	0.261230	0.359863	0.433105	0.453613	0.499023	0.542969	0.616699	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	2.0
99995	99995.0	1.000000	0.677734	0.222412	0.257080	0.204712	0.054657	0.026154	0.118164	0.244873	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
99996	99996.0	0.926758	0.906250	0.637207	0.415039	0.374756	0.382568	0.358887	0.341309	0.336426	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	2.0
99997	99997.0	0.925781	0.587402	0.633301	0.632324	0.639160	0.614258	0.599121	0.517578	0.403809	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	3.0
99998	99998.0	1.000000	0.994629	0.829590	0.458252	0.264160	0.240234	0.213745	0.189331	0.203857	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	2.0
99999	99999.0	0.925781	0.916504	0.404297	0.000000	0.262939	0.385498	0.361084	0.332764	0.339844	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0

方法选用

主要考虑到三种方法

- AdaBoost
- 元分类器是支持向量机 (SVM) 的 AdaBoost
- 随机森林 Random Forest

树形结构的算法大多不需要进行降维处理，可以保持特征的可解释性

AdaBoost

1. 最常见的 AdaBoost 元分类器是决策树，sklearn 中默认使用一层的决策树来作为它的元分类器
2. 尝试以不同层数的决策树作为元分类器，精确度先增加后减少

```
层数>1 精确度均值: 0.650 精确度方差: 0.059
层数>2 精确度均值: 0.767 精确度方差: 0.047
层数>3 精确度均值: 0.873 精确度方差: 0.027
层数>4 精确度均值: 0.926 精确度方差: 0.018
层数>5 精确度均值: 0.938 精确度方差: 0.013
层数>6 精确度均值: 0.947 精确度方差: 0.010
层数>7 精确度均值: 0.947 精确度方差: 0.013
层数>8 精确度均值: 0.951 精确度方差: 0.013
层数>9 精确度均值: 0.951 精确度方差: 0.014
层数>10 精确度均值: 0.950 精确度方差: 0.012
```

AdaBoost + SVM

AdaBoost 接受所有能样本赋权的分类器作为其元分类器

- 最常见的赋权分类器有两种，即决策树和支持向量机
- 将 AdaBoost 和 SVM 结合，尝试找到一个较优的元分类器
- 实际效果和一层决策树的 AdaBoost 一致，并不是很优

```
准确率均值: 0.648 方差: 0.002
```

对比之下，还是决策树更适合与 AdaBoost 搭配

Random Forest

拟合效果：

```
准确率均值: 0.945 方差: 0.016
```

随机森林的优势

1. 随机森林适用于拥有大型数据集的情况，可以处理数千个输入变量而无需变量删除
2. 能够处理很高维度的数据，并且不用做特征选择 (因为特征子集是随机选择的)
3. 可以在大部分数据丢失时保持准确性
4. 模型泛化能力强
5. 对于不平衡的数据集来说，它可以平衡误差
6. 不需要很多参数调整就可以达到不错的效果

选取最优方案

可以看出以 8 层决策树为元分类器的 AdaBoost 和随机森林的准确率较高，表现较好，最终选择使用随机森林

进一步优化

1. PCA 降维，减少随机森林要处理的特征数量，加快随机森林模型的训练速度
2. 对模型进行超参数调优，进一步提高准确率

计算成本高是随机森林的最大缺点之一，如果只想简单地拥有最佳性能的模型，并且可以牺牲解释特征的重要性，那么 PCA 可能会很有用，但并不是必须的

参数调优

考虑对模型在未知数据上的评估性能的影响

1. 参数 n_estimators 的影响最大
2. max_depth 次之，最大深度也代表了最高复杂度
3. min_samples_leaf 和 min_samples_split 并列
4. max_features 对模型的影响较小
5. criterion 一般使用 gini，具体需要视情况而定

交叉验证寻找最优 n_estimators

先以 10 为间隔，可以求出在 71 附近最优
准确率为 0.9484999999999999

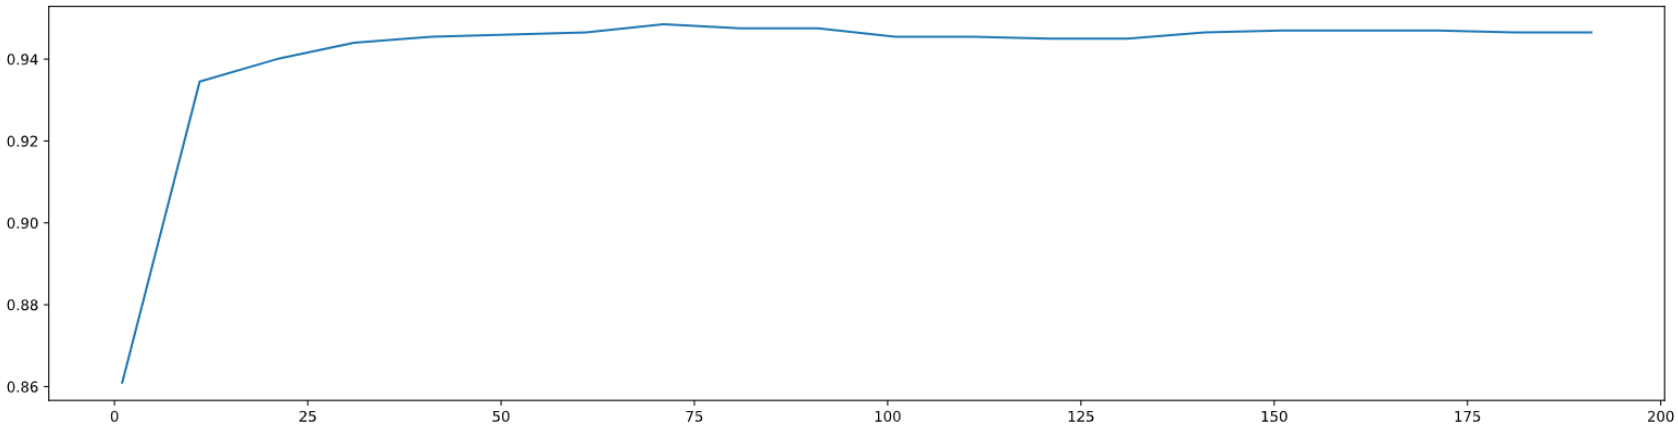

进一步细化，在 65-75 之间以逐个进行寻找
最终得到最优的 n_estimators 为 72
此时准确率提高至 0.9485000000000001

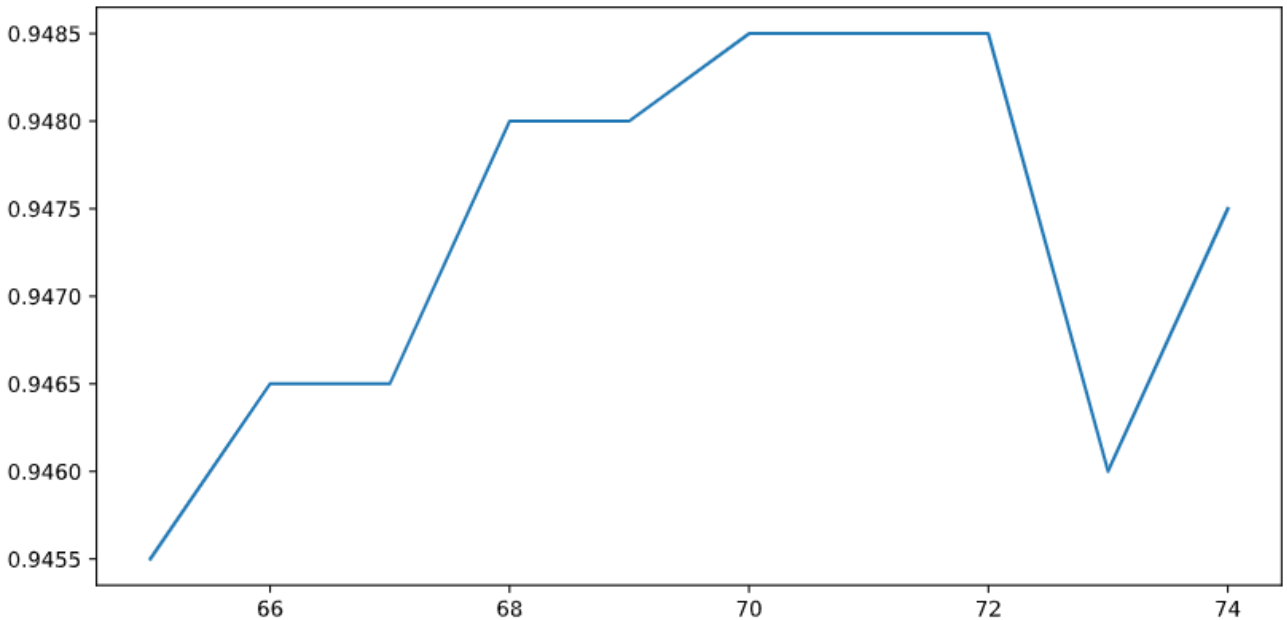

网格搜索对其余参数进行调优

分别对 max_depth min_samples_leaf min_samples_split max_features 进行网格搜索

```
最优分类器: {'max_depth': 24} 最优分数: 0.9485000000000001
最优分类器: {'max_features': 30} 最优分数: 0.9495000000000001
最优分类器: {'min_samples_leaf': 1} 最优分数: 0.9485000000000001
最优分类器: {'min_samples_split': 3} 最优分数: 0.9490000000000001
```

可以发现原模型已经非常接近模型的上限，max_features 对准确度的提升较大
最终得到的模型在准确率上提升了 0.5%

```
准确率均值: 0.950 方差: 0.014
```

参考内容

1. 随机森林 - Random Forest
2. 决策树 VS 随机森林
3. 利用 AdaBoost 元算法提高分类性能
4. 各种机器学习算法的应用场景

Thank you!